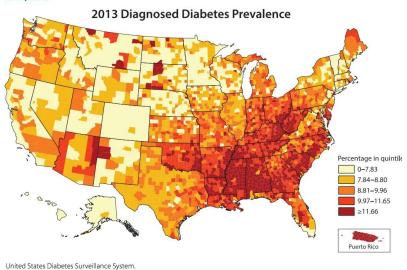
Dla mnie działa

Krótkie omówienie naszego projektu

- plaga chorób związanych z niską aktywnością fizyczną
- trend wzrostowy na rynku urządzeń fitness tracker
- możliwy wzrost zapotrzebowania na rozwiązania mobilne z zakresu fitness (powrót do kondycji po pandemii)

. Age-adjusted, county-level prevalence of diagnosed diabetes among adults aged ≥20 years, tates, 2013

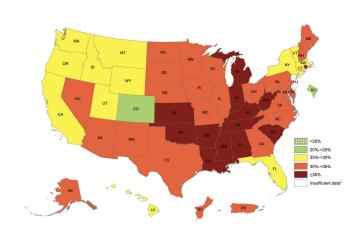


Źródła:

- https://3dinsider.com/wearable-statistics/
- https://www.businessinsider.com/map-of-diabetes-rates-in-the-us-2017-7?IR=T
- https://www.livescience.com/60293-obesity-rates-leveling-off.html

Prevalence† of Self-Reported Obesity Among U.S. Adults by State and Territory, BRFSS, 2019

†Prevalence estimates reflect BRFSS methodological changes started in 2011. These estimates should not be compared to prevalence estimates before 2011.



Fitbit key statistics

- Fitbit generated \$1.13 billion revenue in 2020, a 20 percent loss year-on-year
- In 2020, Fitbit posted a net loss of \$190 million
- Fitbit sold 10.6 million units in 2020, a 31 percent decrease year-on-year
- Over 31 million people use Fitbit once a week

Fitbit users

Year	Users
2014	6.7 million
2015	16.9 million
2016	23.2 million
2017	25.4 million
2018	27.6 million
2019	29.6 million
2020	31 million

Fitbit profit

Year	Profit
2014	\$131 million
2015	\$175 million
2016	(\$102 million)
2017	(\$277 million)
2018	(\$185 million)
2019	(\$320 million)
2020	(\$190 million)

Źródło: https://www.businessofapps.com/data/fitbit-statistics/

Article Published: 11 September 2018

Is Fitbit Charge 2 a feasible instrument to monitor daily physical activity and handbike training in persons with spinal cord injury? A pilot study

Źródło: https://www.nature.com/articles/s41394-018-0113-4

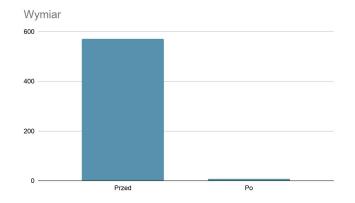
Podsumowanie naszej pracy - od początku



- Pozbyliśmy się wartości NA (wypełniliśmy te pola średnią wartością z kolumn)
- Usunęliśmy duplikaty
- W danych treningowych usunęliśmy wszystkie wiersze, w których znajdowało się więcej niż 5 wartości
 NA (byłyby one niereprezentatywne)
- Oczyściliśmy i przygotowaliśmy dane do dalszej pracy z nimi

Trenowanie i redukcja wymiaru

- Przetestowaliśmy wiele metryk i modeli
- Uzyskaliśmy wysoką precyzję predykcji
- Wyselekcjonowaliśmy najważniejsze cechy
- Dzięki temu znacząco zmniejszyliśmy wymiar
- Z 572 do 7!



Weight	Feature
0.0081 ± 0.0015	tGravityAccmaxY
0.0017 ± 0.0005	tGravityAccminX
0.0017 ± 0.0003	subject
0.0016 ± 0.0013	fBodyGyromaxIndsZ
0.0008 ± 0.0004	tBodyAcccorrelationXY
0.0006 ± 0.0004	tBodyGyromaxX
0.0001 ± 0.0001	fBodyGyromeanFreqX

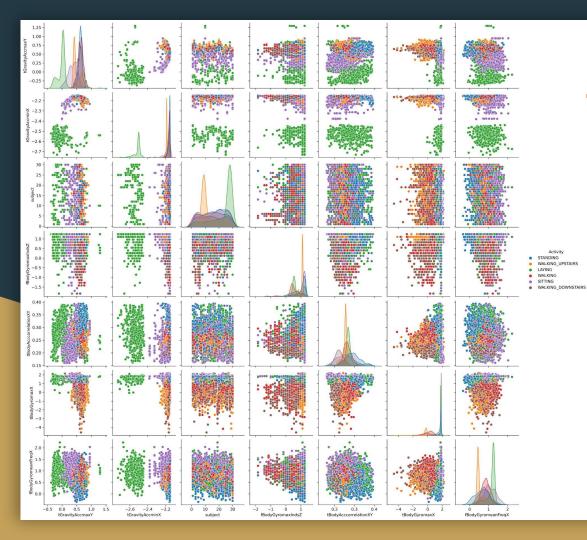
Wybór modelu

- Po porównaniu dokładności jak również szybkości działania poszczególnych algorytmów,
 zdecydowaliśmy się na wykorzystanie modelu LGBMClassifier i metryki f1_micro
- Decyzję podjęliśmy w oparciu o szczegółową analizę, wybrana przez nas konfiguracja zapewniała
 ~98% poprawności predykcji przy rozsądnym czasie wykonania
- Modele testowaliśmy przy pomocy cross-validation oraz podziału danych na treningowe oraz testowe

w proporcji 70:30 z zastosowaniem stratify

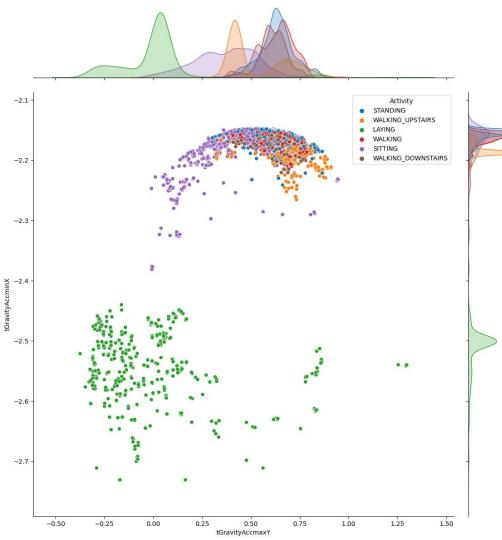
```
metrics = {
    'accuracy': accuracy_score,
    'recall': recall_score,
    'precision': precision_score,
    'f1_score': f1_score,
    'roc_auc': roc_auc_score,
}

models = {
    'LGR': LogisticRegression(solver = 'lbfgs', random_state=42, verbose=0),
    'DTC': DecisionTreeClassifier(random_state=42),
    'RFC': RandomForestClassifier(random_state=42),
    'ETC': ExtraTreesClassifier(random_state=42),
    'XGB': xgb.XGBClassifier(random_state=42),
    'LGBM': lgb.LGBMClassifier(random_state=42),
    # 'CTB': ctb.CatBoostClassifier(verbose=0),
}
```

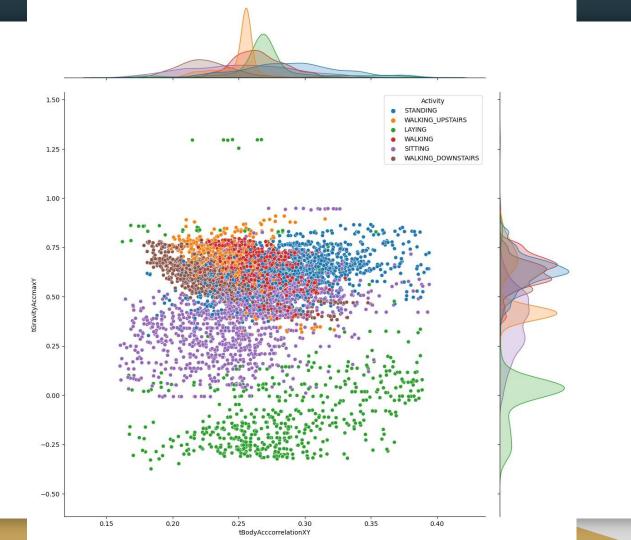


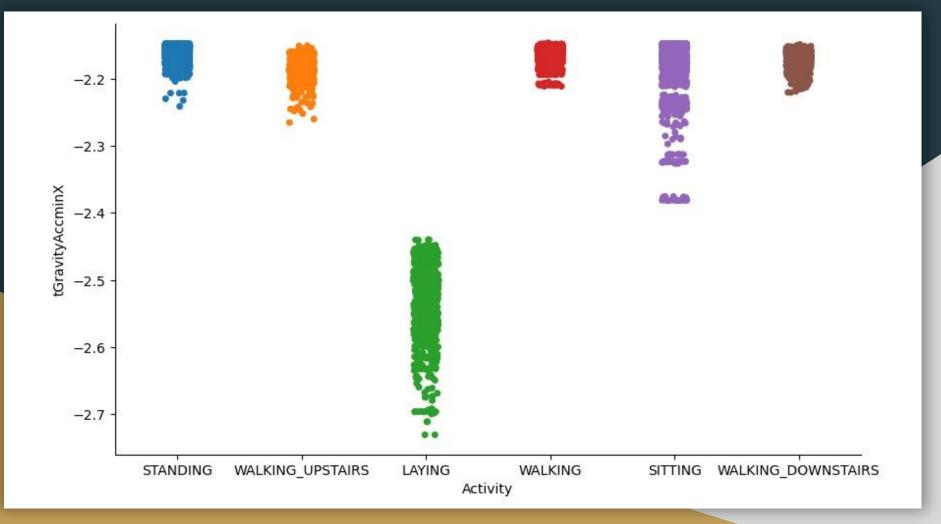
Analiza wyników

Wizualizacja zależności
między 7 najważniejszymi
zmiennymi a kolumną
"Activity" pozwoliła nam
zauważyć interesujące
powiązania



Kluczowa korelacja





Dziękujemy za uwagę

- Jędrzej Dudzicz
- Hubert Masłowski
- Aleksander Malinowski